

EPD EVALUABLE 2

INTELIGENCIA DE NEGOCIO

Clasificación de Grupos de Clientes

Grupo AGMPST

Garrido Massé, Antonio
Sánchez Troncoso, Pablo

Tabla de Contenidos

1. Introducción	1
2. Metodología	1
3. Objetivo del negocio	1
4. Descripción de los datos	1
5. Preparación de los datos	2
5.1. Conversión de tipo de datos	2
5.2. Valores atípicos	2
5.3. Normalización	2
5.4. Agrupación	2
5.5. Reducción de dimensionalidad	2
6. Modelado	3
7. Validación	3
8. Resultados	3
9. Descripción de nodos	4

Tabla de Figuras

Figura 1: Diagrama metodología CRISP-DM	1
Figura 2: Descripción de características	1
Figura 3: Tabla de Frecuencias de Agrupación	2
Figura 4: Gráfico de distribución de las clases	2
Figura 5: Media de característica por agrupación	2
Figura 6: Características seleccionadas	3
Figura 7: Entropía máxima teórica	3
Figura 8: Entropía de las clases objetivo	3
Figura 9: Resultados	3
Figura 10: Descripción de nodos	4

1. Introducción

El responsable de Marketing de una reconocida cadena de supermercados a nivel nacional cuenta con una base de datos proporcionada por una compañía externa.

2. Metodología

Se ha optado por seguir la metodología CRISP-DM. Está estructurada en seis fases distintas, cada una de las cuales representa una etapa clave en el proceso de desarrollo de un proyecto de minería de datos.




Figura 1: Diagrama metodología CRISP-DM

3. Objetivo del negocio

El propósito central de este análisis es realizar un modelo predictivo que clasifique a los clientes en diferentes perfiles, con el fin de maximizar su valor para la empresa y personalizar la oferta de productos según sus hábitos de compra y necesidades específicas.

4. Descripción de los datos

La base de datos proporcionada por la compañía externa cuenta con 2.008 instancias y 23 características de los clientes. Estas vienen descritas a continuación:

Característica Breve descripción

Age	Edad del cliente.
Education	Nivel educativo del cliente.
Living_With	¿El cliente vive con alguien?
Income	Ingreso anual del hogar del cliente.
Kidhome	Número de niños en el hogar del cliente.
Teenhome	Número de adolescentes en el hogar del cliente.
Children	Número de hijos del cliente.
Is_Parent	¿Es el cliente padre/madre?
Family_Size	Número de miembros de la familia del cliente.
Customer_For	Número de días desde que es cliente.
Recency	Número de días desde la última compra del cliente.
Wines	Importe gastado en vino en los últimos 2 años.
Fruits	Importe gastado en frutas en los últimos 2 años.
Meat	Importe gastado en carne en los últimos 2 años.
Fish	Importe gastado en pescado en los últimos 2 años.
Sweets	Importe gastado en dulces en los últimos 2 años.
Gold	Importe gastado en productos gourmet en los últimos 2 años.
NumDeals Purchases	Número de compras realizadas con descuento.
NumWeb Purchases	Número de compras realizadas a través del sitio web de la empresa.
NumCatalog Purchases	Número de compras realizadas mediante catálogo.
NumStore Purchases	Número de compras realizadas directamente en tiendas físicas.
NumWeb VisitsMonth	Número de visitas al sitio web de la empresa en el último mes.
Spent	Importe total gastado en los últimos 2 años.

Figura 2: Descripción de características

Ninguno de los datos proporcionados contienen valores faltantes.

5. Preparación de los datos

Tras una exploración inicial de los datos hemos concluido lo siguiente:

5.1. Conversión de tipo de datos

Algunas variables del conjunto de datos se presentan en formato categórico, el cual no es compatible con los modelos que utilizaremos posteriormente en KNIME. Por esta razón, fue necesario transformar dichas categorías en valores ordinales, permitiendo así su integración en el flujo de modelado.

5.2. Valores atípicos

Identificamos la presencia de valores atípicos a través de un análisis univariante de las características. Dado que la cantidad de valores atípicos detectados es baja y que hemos utilizado el método del rango intercuartílico como criterio de detección, optamos por reemplazarlos por el valor permitido más cercano dentro del rango. Cabe señalar que una posible mejora sería complementar este análisis con métodos multivariantes, que podrían ofrecer una detección más precisa en contextos complejos. Asimismo, sería útil determinar si estos valores atípicos se deben a errores humanos, fallos en la manipulación de los datos o si, por el contrario, representan simplemente valores extremos válidos.

5.3. Normalización

Dado que en la fase de modelado se emplearán algoritmos basados en distancias, es fundamental que las variables no conserven sus unidades originales para evitar sesgos en los cálculos. Para ello, se aplicó una normalización mediante el método min-max, escalando los valores al intervalo [0,1]. Es importante realizar este proceso **después** del tratamiento de valores atípicos, ya que su presencia podría distorsionar el rango utilizado para la normalización y afectar negativamente la calidad de la transformación.

5.4. Agrupación

Posteriormente, aplicamos diversas técnicas de aprendizaje no supervisado con el objetivo de agrupar a los clientes en tres grupos. Tras una evaluación empírica; concluimos que *k-Means* era suficiente para cumplir con los objetivos del proyecto. A continuación se muestra la frecuencia de instancias por agrupación de clientes:

Agrupación	Frec. Absoluta	Fre. Relativa
Grupo #0	715	50.89%
Grupo #1	332	23.63%
Grupo #2	358	25.48%
Total	1.405	100%

Figura 3: Tabla de Frecuencias de Agrupación




Figura 4: Gráfico de distribución de las clases

Al analizar las agrupaciones obtenidas, observamos la siguiente media de cada característica:

Característica	Grupo #0	Grupo #1	Grupo #2
Age	54.3	57.1	59.2
Education	1.2	1.3	1.3
Living_With	0.6	0.6	0.7
Income	36503.1	72843.9	62789.5
Kidhome	0.8	0.0	0.2
Teenhome	0.5	0.0	1.0
Children	1.3	0.0	1.2
Is_Parent	0.9	0.0	1.0
Family_Size	2.9	1.6	2.9
Customer_For	319.6	350.3	408.8
Recency	49.1	50.6	49.7
Wines	62.9	565.7	513.2
Fruits	4.5	45.2	30.8
Meat	25.9	374.4	186.8
Fish	6.4	72.9	46.1
Sweets	4.6	44.9	31.2
Gold	15.6	61.6	63.1
NumDealsPurchases	2.2	1.1	3.3
NumWebPurchases	2.4	5.1	6.4
NumCatalogPurchases	0.6	5.5	3.9
NumStorePurchases	3.4	8.0	8.3
NumWebVisitsMonth	6.4	3.0	5.4
Spent	120.4	1291.6	904.6

Figura 5: Media de característica por agrupación

5.5. Reducción de dimensionalidad

Se exploró la reducción de la dimensionalidad mediante dos enfoques distintos de selección de características, junto con un grupo de control al que no se le aplicó ninguna técnica de selección. Las dos metodologías utilizadas fueron: selección por envoltura (*wrapper*) y selección por filtrado (*filter*).

Determinamos empíricamente que la estrategia de búsqueda más adecuada para este problema era el uso de algoritmos genéticos, ya que el espacio de búsqueda presenta múltiples óptimos locales. Para la estrategia por envoltura se utilizó la métrica de *accuracy*, mientras que en el método de filtrado se empleó el evaluador *CfsSubsetEval*.

Tras aplicar ambas estrategias de selección, se identificaron las siguientes características como las más relevantes para llevar a cabo la tarea de clasificación:

Característica	Envoltura	Filtrado
Age	×	×
Education	×	×
Living_With	×	×
Income	×	×
Kidhome	×	✓
Teenhome	✓	✓
Children	✓	×
Is_Parent	✓	✓
Family_Size	×	✓
Customer_For	×	×
Recency	×	×
Wines	×	✓
Fruits	✓	✓
Meat	✓	×
Fish	✓	×
Sweets	✓	✓
Gold	✓	✓
NumDealsPurchases	×	✓
NumWebPurchases	×	×
NumCatalogPurchases	✓	✓
NumStorePurchases	✓	✓
NumWebVisitsMonth	✓	✓
Spent	✓	✓

Figura 6: Características seleccionadas

6. Modelado

En la fase de modelado, se decidió emplear modelos de Árboles de Decisión (*Decision Trees*, DT) y Bosques Aleatorios (*Random Forests*, RF). Antes de aplicar estos algoritmos, es fundamental verificar que se cumplen las hipótesis necesarias para su uso adecuado. Una de las más relevantes, especialmente para evitar el sobreajuste (*overfitting*), es el balance de las clases objetivo.

Para evaluar dicho balance, se utilizó la métrica de **entropía**. Dado que se trata de un problema con tres clases, la entropía máxima teórica del sistema es:

$$H_{\text{máx}} = -3 \cdot \frac{1}{3} \cdot \log_2 \left(\frac{1}{3} \right) = \log_2(3) \approx 1.585$$

Figura 7: Entropía máxima teórica

A partir de los datos obtenidos en la tabla de frecuencias de agrupación, se calculó una entropía aproximada de:

$$H = - \sum_{i=1}^3 p_i \cdot \log_2(p_i) \approx 1.489$$

Figura 8: Entropía de las clases objetivo

Dado que esta entropía se encuentra lo suficientemente cerca del valor máximo, se concluye que las clases están **moderadamente balanceadas**, por lo que es razonable continuar con el modelado utilizando los modelos propuestos.

7. Validación

Para validar el modelo, se aplicaron dos estrategias: validación cruzada con 10 pliegues (*10-fold cross-validation*) y validación *hold-out* con una partición 70-30. En la validación cruzada, en cada iteración se utiliza el 90 % de las instancias para entrenamiento y el 10 % restante para prueba. En la validación *hold-out*, el conjunto de datos se divide una sola vez, asignando el 70 % a entrenamiento y el 30 % a prueba.

Dado que no se dispone de información previa sobre la pertenencia real de los clientes a cada grupo, no es posible realizar una partición estratificada. Por ello, se optó por un muestreo aleatorio simple, aunque esto puede reducir la representatividad proporcional de las clases en cada partición.

8. Resultados

La métrica utilizada para evaluar el rendimiento de cada modelo fue la **exactitud** (*accuracy*). Cada modelo se identificó según la técnica de validación empleada (XVAL para validación cruzada y Part para validación *hold-out*), la estrategia de selección de características aplicada (Wrap para selección por envoltura, Filter para selección por filtrado y No-FS para el grupo de control sin selección), y el algoritmo utilizado (DT para árboles de decisión y RF para bosques aleatorios).

A continuación se exponen los resultados obtenidos:

Modelo	Exactitud
XVal Wrap DT	95%
XVal Wrap RF	97%
XVal Filter DT	96%
XVal Filter RF	97%
XVal No-FS DT	96%
XVal No-FS RF	97%
Part Wrap DT	97%
Part Wrap RF	97%
Part Filter DT	95%
Part Filter RF	97%
Part No-FS DT	96%
Part No-FS RF	98%

Figura 9: Resultados

9. Descripción de nodos

Nombre	#	Breve Descripción
CSV Reader	#1	Lee el archivo de datos en formato CSV del data area del workflow.
Data transformation	#2	Es un metanodo que renombra la columna Age, convierte a ordinal Education teniendo en cuenta un orden establecido por nosotros y convierte la columna Living With a booleano, si vive solo es falso y no es verdadero.
X-Partitioner	#3	Divide los datos en entrenamiento y test por bolsas haciendo una validación cruzada. Tiene 10 bolsas por lo que cada iteración tiene un 10% de datos para el test.
Outliers	#4, #14	Son metanodos que buscan valores anómalos en los datos y los convierten el valor permitido más cercano, se hace en el conjunto de entrenamiento y se aplica al conjunto de test.
Normalize	#5, #15	Son metanodos que normalizan con Min-Max para que el valor más bajo sea 0 y el más alto 1, haciendo que la diferencia de magnitudes entre características no afecte a técnicas que usen distancia.
Clustering	#6, #16	Son metanodos que usan la técnica de k-Means con k = 3 (formando así tres clusters), encontrando los centroides en los datos de prueba y asignando clusters por el centroide más cercano a los datos de test.
Wrap feature selection	#7, #17	Son metanodos que aplican un método de selección de características por envoltura con los nodos de bucle de selección de características usando algoritmo genético y usando kNN con validación cruzada para predecir y medir el accuracy de cada iteración con diferentes subconjuntos de características para elegir el mejor y usar el nodo feature selection filter para aplicar la selección de características al training y al test. Además, aplica las técnicas de decision tree y random forest para hacer las predicciones correspondientes al método de envoltura.
Filter feature Selection	#8, #18	Estos metanodos usan los nodos de weka de AttributeSelectedClassifier y WekaPredictor para hacer una selección de características por filtrado, entrenar y predecir con decision tree y random forest.
Without feature selection	#9, #19	Son metanodos que aplican decision tree y random forest sin hacer selección de características previa.

Scoring	#10, #20	Estos metanodos usan el nodo scorer y variable to table row para generar los accuracy de cada uno de los modelos en forma de salida de tablas.
Loop end	#11	Al tener varios modelos dentro del mismo X-Partitioner hemos tenido que usar este nodo en vez del estándar X-Aggregator, este nodo recoge los accuracy de cada iteración y cada técnica para ser tratados posteriormente.
Mean	#12	Metanodo que calcula la media de las 10 iteraciones del X-Partitioner para tener un solo accuracy para cada modelo.
Partitioning	#13	Este nodo se encarga de dividir el conjunto de datos en entrenamiento y test con un 70% para entrenamiento y un 30% para test.
Features Extraction Statistics	#21	Usa los nodos de column filter para eliminar el cluster y la predicción y el nodo de column name extractor para obtener los nombres de las columnas usadas en los features selection (el de filtrado no se ha podido poner por que weka no filtra en la salida).
Table View	#22, #23	Son nodos para visualizar lo conseguido en el nodo #21
Statistics View	#24	Nodo que muestra las estadísticas de cada característica de los datos, nos servirá para poder conocer mejor los datos y tomar decisiones respecto a esa información.
Pie Chart	#25	Gráfico que muestra la proporción de cada cluster encontrado, para evitar posibles desbalances.
Image Writer (Port)	#26	Nodo que escribe la imagen generada en el nodo #25 en la carpeta de data del workflow.
Cluster Statistics	#27	Obtiene la media de todos los elementos de cada cluster.
Table View	#28	Nodo que muestra los resultados del metanodo #27.
Result transformer	#29	Concatena todos los resultados de los accuracy de los nodos #10, #20 y les pone los nombres de cada método para poder identificarlos.
Table View	#30	Muestra los resultados del nodo #29.

Figura 10: Descripción de nodos